



Université Abdelmalek Essaâdi
Faculté des Sciences et Techniques – Tanger



MASTER SCIENCES ET TECHNIQUES
INTELLIGENCE ARTIFICIELLE ET SCIENCES DES DONNÉES

Module : Business Intelligence, Data Mining

Rapport de projet
Grocery Sales BI Dashboard
Business Intelligence, Data Mining et Prévision des ventes

Conception d'une solution analytique complète pour l'étude des ventes d'une enseigne de distribution alimentaire.

Encadré par :

Pr. Salma Chrit

Réalisé par :

*Amami Yousra
Hamdan Kaouthar
Zarqi Ezzoubair
EL gharib Mahmoud
EL Attar Mohamed*

Année Universitaire 2025–2026

Table des matières

	Résumé	1
1	Introduction générale	2
1.1	Contexte	2
1.2	Besoins traités par le projet	2
1.3	Problématique	3
1.4	Objectifs du projet	3
1.5	Méthodologie	4
2	Présentation des données	5
2.1	Source du jeu de données	5
2.2	Tables métier	6
2.3	Description des principales entités	6
2.3.1	Produits et catégories	6
2.3.2	Clients	6
2.3.3	Employés	7
2.3.4	Ventes	7
2.4	Jeu de données dénormalisé	7
2.5	Variables importantes	8
2.6	Préparation des données	8
2.7	Contrôles de qualité	9
3	Architecture Décisionnelle	10
3.1	Vue d'ensemble de l'architecture	10
3.2	Modélisation : Le Schéma en Étoile	10
3.2.1	Table de faits	11
3.2.2	Dimensions	11
3.3	Le Pipeline ETL avec Apache Hop	12
3.3.1	Objectif du pipeline	12
3.3.2	Source de données et structure générale	13
3.4	Logique de traitement et de chargement	13
3.4.1	Alimentation des Dimensions (Flux standard)	13
3.4.2	Alimentation de la Table de Faits (Flux de masse)	13

TABLE DES MATIÈRES

3.5	Gouvernance et Industrialisation du Pipeline	14
3.5.1	Synthèse des composants du pipeline	14
3.5.2	Ordonnancement et Intégrité Référentielle	14
3.5.3	Contrôles Qualité et Idempotence	15
4	Tableaux de bord Power BI	16
4.1	Objectif général	16
4.2	Page ventes	16
4.3	Page produits	17
4.4	Page clients	19
4.5	Page employés	20
4.6	Synthèse des apports des tableaux de bord	21
5	Data Mining : Analyse du panier	22
5.1	Introduction	22
5.2	Objectif de l'analyse	22
5.3	Données utilisées	23
5.4	Principe méthodologique	23
5.5	Métriques d'association	24
5.5.1	Support	24
5.5.2	Confidence	24
5.5.3	Lift	25
5.6	Intégration dans Power BI	26
5.7	Interprétation des résultats	27
5.8	Exploitation commerciale des résultats	27
5.9	Limites de l'analyse	28
5.10	Conclusion	28
6	Machine Learning : Prédiction du chiffre d'affaires	30
6.1	Introduction	30
6.2	Construction de la série temporelle	30
6.3	Préparation des données	31
6.3.1	Traitement des valeurs aberrantes	31
6.3.2	Création des variables de retard	31
6.3.3	Création des moyennes mobiles	32
6.3.4	Variables calendaires	32
6.3.5	Séparation entraînement-test	32
6.4	Modèles étudiés	32
6.4.1	Holt-Winters	32
6.4.2	XGBoost	33

6.4.3	Random Forest	33
6.4.4	SARIMA	33
6.4.5	Ensemble pondéré	34
6.5	Résultats expérimentaux	34
6.6	Analyse des résultats	34
6.7	Conclusion	35
7	Discussion et limites	36
7.1	Analyse critique du projet	36
7.2	Forces du projet	36
7.2.1	Une chaîne décisionnelle complète	36
7.2.2	Une modélisation adaptée à l'analyse décisionnelle	37
7.2.3	Des tableaux de bord orientés métier	37
7.2.4	Une dimension Data Mining à forte valeur ajoutée	37
7.2.5	Une approche comparative en Machine Learning	38
7.3	Limites identifiées	38
7.3.1	Gestion des relances du pipeline ETL	38
7.3.2	Automatisation limitée des contrôles qualité	39
7.3.3	Absence d'orchestration centralisée	39
7.3.4	Industrialisation limitée des modèles prédictifs	39
7.3.5	Limites liées aux données	40
7.4	Perspectives et améliorations futures	40
7.4.1	Renforcement de la qualité des données	40
7.4.2	Automatisation complète de la chaîne décisionnelle	41
7.4.3	Évolution du Data Mining	41
7.4.4	Amélioration des modèles de prévision	41
7.4.5	Déploiement en environnement réel	41
8	Conclusion	43
A	Annexes	44
A.1	Organisation du projet	44
A.2	Technologies utilisées	44

Table des figures

1.1	Démarche générale du projet	4
3.1	Pipeline Apache Hop utilisé pour charger le schéma décisionnel	10
3.2	Le Schéma en Étoile	12
4.1	Tableau de bord d’analyse des ventes	17
4.2	Tableau de bord d’analyse des produits	18
4.3	Tableau de bord d’analyse des clients	19
4.4	Tableau de bord d’analyse des employés	20
5.1	Tableau de bord Power BI dédié à l’analyse du panier	26

Liste des tableaux

2.1	Principales tables utilisées dans le projet	6
2.2	Axes analytiques rendus possibles par le dataset	7
3.1	Structure du schéma en étoile	11
3.2	Synthèse des opérations du pipeline ETL Apache Hop	14
5.1	Exemple simplifié de structure transactionnelle utilisée pour l'analyse du panier	23
5.2	Interprétation de la métrique Lift	25
6.1	Exemple simplifié de série temporelle mensuelle	31
6.2	Comparaison des performances des modèles	34
A.1	Synthèse des technologies utilisées	44

Résumé

Ce projet présente la mise en place d'une chaîne décisionnelle complète appliquée à un jeu de données de ventes alimentaires. L'objectif est de transformer des données transactionnelles brutes en informations exploitables pour le pilotage commercial : suivi du chiffre d'affaires, analyse des produits, compréhension du comportement client, évaluation des employés, détection d'associations entre produits et prévision des revenus.

La solution repose sur une architecture de bout en bout. Les données sont d'abord préparées avec Python, puis chargées dans un entrepôt PostgreSQL selon un schéma en étoile à l'aide d'Apache Hop. Les tableaux de bord Power BI permettent ensuite une exploration interactive des indicateurs clés. Enfin, une couche analytique avancée complète le système avec une analyse du panier et des modèles de prévision de séries temporelles.

Apport principal du projet

Le projet ne se limite pas à la visualisation. Il relie la préparation des données, l'industrialisation ETL, la modélisation décisionnelle, l'analyse métier et l'apprentissage automatique dans une même démarche cohérente.

Chapitre 1

Introduction générale

1.1 Contexte

Les entreprises de distribution génèrent quotidiennement un volume important de données : tickets de caisse, produits vendus, clients, employés, remises, dates et montants. Ces données sont riches, mais leur valeur dépend de la capacité à les nettoyer, les structurer et les restituer sous forme d'indicateurs compréhensibles.

Dans ce contexte, la Business Intelligence permet de construire un socle de pilotage fiable. Elle aide les responsables à répondre à des questions concrètes : quels produits génèrent le plus de chiffre d'affaires, quelles catégories progressent, quels clients sont les plus importants, quels employés réalisent les meilleures performances et quelles associations de produits peuvent soutenir des actions de vente croisée.

1.2 Besoins traités par le projet

Le projet répond à un besoin central : passer d'un ensemble de données transactionnelles dispersées à un système d'aide à la décision clair, fiable et exploitable par un responsable métier. Dans un environnement de vente alimentaire, les décisions doivent être prises rapidement : suivre les revenus, comprendre les produits performants, identifier les clients importants, évaluer l'activité commerciale et anticiper la demande.

Les besoins traités peuvent être regroupés en cinq axes :

- **Besoin de visibilité commerciale** : disposer d'une vue globale sur le chiffre d'affaires, les quantités vendues, les transactions et le panier moyen.
- **Besoin d'analyse produit** : repérer les produits et catégories les plus rentables, les références à faible performance et les relations entre prix, volume et chiffre d'affaires.
- **Besoin de connaissance client** : distinguer les clients actifs, les meilleurs clients, les segments à forte valeur et la répartition géographique de la clientèle.
- **Besoin de pilotage des employés** : mesurer la contribution des vendeurs, comparer

les performances et suivre l'évolution mensuelle de l'activité.

- **Besoin d'analyse avancée** : détecter les produits souvent achetés ensemble et prévoir le chiffre d'affaires futur afin de mieux orienter les recommandations, les promotions et la planification.

Ainsi, la solution proposée ne se limite pas à produire des graphiques. Elle structure toute la chaîne analytique, depuis la préparation des données jusqu'à la restitution décisionnelle et la prévision.

1.3 Problématique

La problématique du projet peut être formulée ainsi :

Comment concevoir une solution analytique capable de transformer des données de ventes alimentaires en tableaux de bord décisionnels, en règles d'association produit et en prévisions de chiffre d'affaires ?

Cette problématique implique plusieurs exigences : disposer de données propres, créer un modèle adapté au reporting, automatiser le chargement, proposer des visualisations utiles et intégrer des méthodes analytiques avancées.

1.4 Objectifs du projet

Les objectifs principaux sont les suivants :

- préparer un jeu de données exploitable à partir de données de ventes alimentaires ;
- construire un modèle décisionnel en étoile dans PostgreSQL ;
- développer un pipeline ETL avec Apache Hop ;
- concevoir des tableaux de bord Power BI pour les ventes, les produits, les clients, les employés et l'analyse du panier ;
- calculer des règles d'association avec les métriques support, confiance et lift ;
- comparer plusieurs modèles de prévision du chiffre d'affaires ;
- documenter clairement l'architecture et les résultats obtenus.

1.5 Méthodologie

La démarche suivie est progressive. Elle commence par l'étude des sources de données, continue avec la préparation et la modélisation, puis aboutit à la restitution visuelle et à l'analyse prédictive.



FIGURE 1.1 – Démarche générale du projet

Chapitre 2

Présentation des données

2.1 Source du jeu de données

Le projet s'appuie sur le jeu de données *Grocery Sales Database*, publié sur Kaggle par l'utilisateur *andrexibiza* **andrexibiza2024grocery**.

Ce jeu de données simule l'activité commerciale d'une enseigne de distribution alimentaire. Il contient des informations relationnelles liées aux ventes, aux produits, aux catégories, aux clients, aux employés, aux villes et aux pays. Cette structure est particulièrement intéressante pour un projet décisionnel, car elle permet de construire des analyses selon plusieurs axes métier : temps, produit, client, employé et zone géographique.

Les données initiales représentent des transactions commerciales. Chaque transaction est rattachée à un produit, un client, un employé et une date. Cette structure permet d'analyser les ventes selon plusieurs dimensions métier.

Intérêt du dataset

Le dataset est adapté à une démarche BI complète, car il ne contient pas seulement des ventes. Il fournit aussi les référentiels nécessaires pour enrichir les faits : produits, catégories, clients, employés et localisation. Il devient donc possible de passer d'une simple analyse de transactions à un véritable modèle décisionnel.

2.2 Tables métier

Table	Type	Description
categories	Référentiel	Familles de produits utilisées pour regrouper les articles dans les analyses.
products	Référentiel	Informations produits : nom, prix, catégorie, classe, résistance, allergie et durée de vitalité.
customers	Référentiel	Données clients : identité, adresse, ville, pays et code postal.
employees	Référentiel	Données employés : identité, date de naissance, genre, date d'embauche et ville.
cities	Géographie	Liste des villes permettant de rattacher clients et employés à une localisation.
countries	Géographie	Pays et codes pays associés aux villes.
sales	Table transactionnelle	Faits de ventes : quantités, remises, prix total, date, heure et numéro de transaction.

TABLE 2.1 – Principales tables utilisées dans le projet

2.3 Description des principales entités

2.3.1 Produits et catégories

Les tables `products` et `categories` décrivent l'offre commerciale. Elles permettent d'analyser les ventes par article, par famille de produits et par caractéristiques produit. Les champs tels que le prix, la classe, la résistance, l'indicateur allergène ou la durée de vitalité apportent un contexte utile pour comparer les performances.

Dans Power BI, ces informations servent à construire des visuels comme le chiffre d'affaires par produit, la distribution des prix, les produits les plus vendus ou encore la relation entre prix unitaire et volume vendu.

2.3.2 Clients

La table `customers` contient les informations d'identification et de localisation des clients. Elle rend possible l'analyse de la valeur client, du nombre de clients actifs, de la répartition géographique et des segments de clientèle.

Pour un décideur, cette dimension permet de répondre à des questions concrètes : quels clients génèrent le plus de revenus, quels pays concentrent l'activité, et quels

segments méritent une action de fidélisation.

2.3.3 Employés

La table `employees` fournit les informations nécessaires au suivi de la performance commerciale. Les ventes étant rattachées aux employés, il devient possible de mesurer le chiffre d'affaires par vendeur, le taux d'activité, l'évolution mensuelle et l'impact de critères comme l'ancienneté.

2.3.4 Ventes

La table `sales` est la table centrale du dataset. Elle contient les mesures nécessaires au calcul des KPI : quantité vendue, remise, prix total, date de vente, heure et transaction. Elle joue le rôle de table de faits dans le futur entrepôt décisionnel.

Axe d'analyse	Exemples de questions traitées
Temps	Comment évolue le chiffre d'affaires par mois, trimestre ou année ?
Produit	Quels produits et catégories génèrent le plus de revenus ?
Client	Quels clients sont actifs et quels clients ont la plus forte valeur ?
Employé	Quels vendeurs contribuent le plus au chiffre d'affaires ?
Panier	Quels produits sont fréquemment achetés ensemble ?
Prévision	Quel chiffre d'affaires peut-on anticiper pour les périodes futures ?

TABLE 2.2 – Axes analytiques rendus possibles par le dataset

2.4 Jeu de données dénormalisé

Pour faciliter les traitements analytiques et l'alimentation du datawarehouse, un fichier dénormalisé est utilisé comme source intermédiaire. Il regroupe sur une même ligne les informations nécessaires à la construction des dimensions et de la table de faits : informations de vente, produit, catégorie, client, employé et localisation.

Cette approche simplifie le pipeline ETL : une seule source CSV est lue, puis divisée en plusieurs branches correspondant aux tables cibles. Elle est particulièrement adaptée à un projet pédagogique, car elle rend visible le passage entre un fichier plat et un modèle décisionnel structuré.

Rôle du fichier dénormalisé

Le fichier dénormalisé sert de pont entre les données relationnelles initiales et le modèle décisionnel. Il permet de charger les dimensions par déduplication, puis de charger la table de faits avec les identifiants et mesures nécessaires.

2.5 Variables importantes

Les variables utilisées dans le projet peuvent être classées selon leur rôle analytique :

- **Identifiants** : SalesID, ProductID, CustomerID, EmployeeID, CategoryID, TransactionNumber.
- **Mesures commerciales** : Quantity, Discount, TotalPrice, Price.
- **Variables temporelles** : date de vente, heure, mois, trimestre et année.
- **Descripteurs produit** : nom du produit, catégorie, classe, résistance, allergie et durée de vitalité.
- **Descripteurs client et employé** : nom, ville, pays, genre, date de naissance et date d'embauche.

Cette organisation facilite la création des mesures DAX dans Power BI, par exemple le chiffre d'affaires total, le panier moyen, la quantité vendue, le nombre de transactions ou le taux d'activité des employés.

2.6 Préparation des données

La phase de préparation est réalisée dans des notebooks Python, principalement avec la bibliothèque `pandas`. Elle vise à rendre les données cohérentes avant leur chargement dans PostgreSQL et leur exploitation dans Power BI. Les traitements appliqués consistent notamment à :

- inspecter les colonnes et les types ;
- nettoyer les valeurs manquantes ou incohérentes ;
- convertir les dates dans un format exploitable ;
- vérifier les doublons ;
- créer un fichier analytique dénormalisé ;
- produire des agrégations utiles pour les analyses ultérieures.

La préparation permet aussi de créer des variables temporelles utiles pour la visualisation et la prévision, comme le mois, l'année, les retards temporels et les moyennes mobiles. Ces variables sont ensuite exploitées dans les tableaux de bord et dans les modèles de Machine Learning.

Qualité attendue des données

Une attention particulière est portée à la cohérence des identifiants, au format des dates, aux montants de vente, aux quantités et aux relations entre faits et dimensions. Ces contrôles conditionnent la fiabilité des indicateurs Power BI et des modèles de prévision.

2.7 Contrôles de qualité

Avant l'analyse, plusieurs contrôles sont nécessaires afin de garantir la fiabilité des résultats :

- vérifier que les identifiants primaires ne contiennent pas de doublons dans les dimensions ;
- contrôler que chaque vente référence bien un produit, un client et un employé existants ;
- s'assurer que les quantités et les montants sont positifs ou métier-valides ;
- vérifier la cohérence entre `Quantity`, `Price` et `TotalPrice` ;
- convertir toutes les dates vers un format unique ;
- contrôler les valeurs extrêmes qui peuvent fausser les KPI ou les modèles prédictifs.

Ces contrôles sont importants, car une erreur dans les données sources peut se propager dans l'entrepôt, dans les mesures Power BI et dans les prévisions.

Chapitre 3

Architecture Décisionnelle

3.1 Vue d'ensemble de l'architecture

L'architecture retenue suit une logique classique de Business Intelligence (BI). Les données brutes sont extraites, préparées, puis chargées dans un entrepôt de données relationnel PostgreSQL avant d'être exploitées et visualisées dans Power BI.

L'élément central de cette architecture est le pipeline ETL (Extract, Transform, Load), qui assure la transition fluide entre le stockage brut et le modèle analytique.




FIGURE 3.1 – Pipeline Apache Hop utilisé pour charger le schéma décisionnel

3.2 Modélisation : Le Schéma en Étoile

Le modèle de données cible implanté dans PostgreSQL est un schéma en étoile. Il est composé de quatre dimensions principales et d'une table de faits. Ce type de

modélisation est particulièrement adapté aux outils de reporting comme Power BI, car il facilite les agrégations, optimise les filtres et fluidifie la navigation analytique.

Table	Grain	Rôle analytique
dim_category	Une ligne par catégorie	Analyse des ventes par famille de produits.
dim_product	Une ligne par produit	Étude des prix, classes, résistances et performances produit.
dim_customer	Une ligne par client	Analyse de la valeur client et de la répartition géographique.
dim_employee	Une ligne par employé	Évaluation de la performance commerciale individuelle.
fact_sales	Une ligne par ligne de vente	Mesure des quantités, remises, montants et transactions.

TABLE 3.1 – Structure du schéma en étoile

3.2.1 Table de faits

La table `fact_sales` centralise les mesures principales de l'activité : quantité vendue, remise, prix total, date, numéro de transaction et heure. Elle contient également les clés étrangères permettant de rejoindre les dimensions produit, client et employé.

Le grain retenu est **la ligne de vente**. Ce niveau de détail est suffisamment fin pour calculer des indicateurs globaux, mais aussi pour mener des analyses plus avancées comme l'étude du panier d'achat ou des tendances temporelles micro-économiques.

3.2.2 Dimensions

Les dimensions apportent le contexte métier indispensable à l'analyse des ventes :

- **La dimension produit (`dim_product`)** : décrit les articles vendus, leur prix et leurs caractéristiques spécifiques ;
- **La dimension client (`dim_customer`)** : permet d'analyser la répartition démographique et la valeur de la clientèle ;
- **La dimension employé (`dim_employee`)** : sert à mesurer l'activité et la performance commerciale des vendeurs ;
- **La dimension catégorie (`dim_category`)** : facilite les regroupements de produits et les analyses macro.




FIGURE 3.2 – Le Schéma en Étoile

3.3 Le Pipeline ETL avec Apache Hop

3.3.1 Objectif du pipeline

Le pipeline ETL constitue le moteur d’alimentation de notre architecture. Son objectif est de transformer un fichier CSV unique et dénormalisé en un schéma en étoile structuré et indexé sous PostgreSQL.

L’intérêt principal d’Apache Hop réside dans sa représentation visuelle et métaphorique du flux de données : chaque transformation est matérialisée par une étape graphique, contrôlable et reliée directement aux tables cibles.

Le flux respecte le triptyque décisionnel standard :

- **Extract** : Lecture du fichier CSV dénormalisé contenant l’historique brut des ventes ;
- **Transform** : Tri, déduplication, typage des données et sélection des colonnes requises ;
- **Load** : Insertion optimisée des données dans les tables respectives du schéma en étoile.

Rôle d’Apache Hop :

Apache Hop permet de rendre le chargement plus lisible et plus contrôlable qu’un simple script SQL ou Python. Il montre clairement comment une source plate unique est divisée en plusieurs branches autonomes pour alimenter simultanément les dimensions et la table de faits.

3.3.2 Source de données et structure générale

Le pipeline utilise en entrée le fichier `grocery_sales_denormalized.csv`. Ce fichier intermédiaire regroupe l'ensemble des données opérationnelles de manière plate.

Le flux débute par une étape *CSV file input* qui transmet l'ensemble des flux vers 5 branches distinctes, chacune correspondant à une table cible du schéma :

1. `dim_category`
2. `dim_product`
3. `dim_customer`
4. `dim_employee`
5. `fact_sales`

3.4 Logique de traitement et de chargement

3.4.1 Alimentation des Dimensions (Flux standard)

Le fichier source contenant plusieurs lignes de vente pour un même client ou produit, les dimensions subiraient des violations de clé primaire sans un traitement de déduplication. Chaque branche de dimension applique donc la séquence rigoureuse suivante :

Sort rows → Unique rows → Select values → Table output

- **Sort rows** : Trie les lignes selon l'identifiant métier (`productid`, `customerid`, etc.). Ce tri est un prérequis technique pour l'étape suivante.
- **Unique rows** : Supprime les doublons consécutifs pour ne conserver qu'une seule occurrence par entité.
- **Select values** : Filtre et mappe les colonnes pour correspondre exactement à la structure de la table PostgreSQL cible (Exemple pour `dim_product` : conservation de `productid`, `productname`, `price`, `class`, etc.).
- **Table output** : Insère les enregistrements épurés dans PostgreSQL.

3.4.2 Alimentation de la Table de Faits (Flux de masse)

Contrairement aux dimensions, la table `fact_sales` ne doit pas être dédupliquée puisque chaque ligne représente un acte d'achat distinct. De plus, le volume y est nettement plus massif.

Le pipeline adopte ici une approche orientée performance :

CSV file input $\longrightarrow$ Select values $\longrightarrow$ PostgreSQL Bulk Loader

L'utilisation du *PostgreSQL Bulk Loader* à la place d'un *Table output* classique permet d'utiliser les API d'écriture de masse (comme la commande `COPY` de PostgreSQL), accélérant drastiquement le temps de chargement global.

3.5 Gouvernance et Industrialisation du Pipeline

3.5.1 Synthèse des composants du pipeline

Table cible	Transformations configurées	Objectif technique
dim_category	Sort rows, Unique rows, Select values, Table output	Extraction et isolation des catégories uniques.
dim_product	Sort rows, Unique rows, Select values, Table output	Structuration des fiches produits et attributs associés.
dim_customer	Sort rows, Unique rows, Select values, Table output	Consolidation du référentiel client et géographie.
dim_employee	Sort rows, Unique rows, Select values, Table output	Cartographie du personnel commercial.
fact_sales	Select values, PostgreSQL Bulk Loader	Chargement haute performance des métriques de vente.

TABLE 3.2 – Synthèse des opérations du pipeline ETL Apache Hop

3.5.2 Ordonnancement et Intégrité Référentielle

Pour respecter les contraintes de clés étrangères (*FK*) définies dans la base de données, l'ordre d'exécution est critique. La table de faits ne peut pointer vers des identifiants inexistantes. Le chaînage du pipeline impose l'ordre strict suivant :

1. `dim_category`
2. `dim_product` (dépendante de la catégorie)
3. `dim_customer`
4. `dim_employee`
5. `fact_sales` (en clôture de traitement)

3.5.3 Contrôles Qualité et Idempotence

Pour assurer la robustesse de l'architecture face aux pannes ou aux exécutions multiples, deux mécanismes sont intégrés :

- **Data Quality** : Validation des formats de date, du séparateur de fichier CSV, et vérification de la non-nullité des indicateurs clés (`quantity`, `totalprice`).
- **Gestion des relances (Idempotence)** : Afin d'éviter la duplication des données en cas de ré-exécution du pipeline, une stratégie de **Truncate-and-Load** est appliquée. Les tables sont vidées par une instruction `TRUNCATE` en amont du chargement complet, garantissant un état propre et reproductible.

Chapitre 4

Tableaux de bord Power BI

4.1 Objectif général

La dernière étape du projet consiste à exploiter l'entrepôt de données à travers des tableaux de bord interactifs réalisés avec Power BI. Cette phase permet de transformer les données structurées dans PostgreSQL en informations visuelles, compréhensibles et directement exploitables pour la prise de décision.

L'objectif principal des tableaux de bord est de fournir une vision synthétique et dynamique de l'activité commerciale. Les utilisateurs peuvent analyser les performances globales, suivre l'évolution des ventes, comparer les produits, étudier le comportement des clients, mesurer la contribution des employés et explorer les associations entre produits.

L'interface Power BI a été organisée autour de cinq pages thématiques :

- une page dédiée à la performance des ventes ;
- une page consacrée à l'analyse des produits ;
- une page centrée sur le comportement des clients ;
- une page dédiée à la performance des employés ;
- une page d'analyse du panier basée sur les règles d'association.

Chaque page regroupe des indicateurs clés de performance, des visualisations analytiques et des filtres permettant d'explorer les données selon différents axes : année, catégorie, ville, employé ou type de produit. Cette organisation facilite la lecture des résultats et permet de répondre rapidement aux besoins de pilotage.

4.2 Page ventes

La page des ventes constitue la vue principale du tableau de bord. Elle fournit une vision globale de la performance commerciale de l'entreprise à travers les indicateurs les plus importants : le chiffre d'affaires total, la quantité totale vendue et le nombre de

transactions.



FIGURE 4.1 – Tableau de bord d'analyse des ventes

Comme le montre la figure 4.1, cette page permet de suivre l'évolution des ventes selon plusieurs dimensions. La courbe mensuelle met en évidence la saisonnalité de l'activité et permet d'identifier les périodes de forte ou de faible demande. Le graphique d'évolution annuelle permet, quant à lui, d'observer la dynamique de croissance du chiffre d'affaires sur plusieurs années.

La carte géographique offre une lecture spatiale de la performance commerciale en représentant la contribution des différentes villes. Elle permet d'identifier les zones générant le plus de ventes et celles présentant un potentiel d'amélioration. Le classement des meilleures villes complète cette analyse en mettant en avant les marchés les plus performants.

Cette page répond donc à plusieurs questions décisionnelles essentielles : quelle est la performance globale de l'entreprise ? Quels mois génèrent le plus de ventes ? Quelles villes contribuent le plus au chiffre d'affaires ? Comment évolue la croissance commerciale dans le temps ?

4.3 Page produits

La page produits est consacrée à l'analyse de la performance des références commercialisées. Elle permet d'étudier le chiffre d'affaires et la quantité vendue selon les catégories et les produits.



FIGURE 4.2 – Tableau de bord d'analyse des produits

La figure 4.2 présente plusieurs visualisations permettant d'évaluer la contribution des produits au résultat commercial. Le graphique en arborescence met en évidence la répartition du chiffre d'affaires par catégorie. Il permet d'identifier rapidement les catégories les plus rentables, telles que les catégories générant les plus grands montants de ventes.

Les graphiques de classement présentent les meilleurs et les moins bons produits selon le volume vendu. Cette comparaison est importante, car elle permet de distinguer les produits à forte rotation des produits à faible contribution. Elle peut ainsi orienter les décisions liées à l'approvisionnement, à la mise en avant commerciale ou à la suppression éventuelle de certaines références.

La page inclut également une analyse des caractéristiques des produits, notamment selon les attributs `isallergic` et `resistant`. Ces informations permettent d'aller au-delà de la simple analyse des ventes et d'étudier la composition du catalogue produit.

Cette page aide donc à répondre aux questions suivantes : quelles catégories génèrent le plus de chiffre d'affaires ? Quels produits sont les plus vendus ? Quels produits ont une faible performance ? Comment les caractéristiques des produits influencent-elles leur présence dans le catalogue ?

4.4 Page clients

La page clients a pour objectif d'analyser la valeur et le comportement de la clientèle. Elle permet d'étudier le nombre de clients, le nombre de clients actifs, le panier moyen, la fréquence d'achat et le taux de réachat.




FIGURE 4.3 – Tableau de bord d'analyse des clients

La figure 4.3 montre une vue orientée vers la connaissance client. Les indicateurs situés en haut de la page donnent une synthèse de la base clientèle et de son activité. Le panier moyen client permet d'évaluer la valeur moyenne générée par un client, tandis que la fréquence d'achat renseigne sur l'intensité de la relation commerciale.

Les graphiques de classement permettent d'identifier les meilleurs clients et les clients les moins performants selon le nombre de transactions. Cette information est utile pour mettre en place des actions de fidélisation, de relance ou de segmentation marketing.

La carte géographique permet également d'analyser la répartition des clients selon les villes ou les zones géographiques. Elle apporte une vision territoriale du comportement client et peut aider à adapter les actions commerciales selon les régions.

Cette page répond à des questions importantes pour la gestion de la relation client : quels sont les clients les plus actifs ? Quelle est la valeur moyenne d'un client ? Quelles zones géographiques concentrent le plus d'activité ? Quels clients nécessitent une action de fidélisation ou de relance ?

4.5 Page employés

La page employés permet d'évaluer la contribution des vendeurs à la performance commerciale globale. Elle présente le nombre total d'employés, les ventes moyennes par employé et un classement individuel selon le chiffre d'affaires généré.




FIGURE 4.4 – Tableau de bord d'analyse des employés

Comme présenté dans la figure 4.4, cette page met en relation la performance commerciale avec certaines caractéristiques des employés, notamment la tranche d'âge, le genre et la catégorie d'âge. Les graphiques permettent d'observer la répartition des employés selon ces dimensions et d'analyser leur contribution au chiffre d'affaires.

Le tableau de classement permet d'identifier les employés ayant réalisé les meilleures performances. Il offre une vue détaillée du chiffre d'affaires généré par chaque employé ainsi que du taux de croissance associé. Cette information peut être utilisée pour le suivi des objectifs, l'évaluation commerciale ou l'identification des bonnes pratiques.

L'analyse par tranche d'âge permet également d'observer si certaines catégories d'employés contribuent davantage aux ventes. Toutefois, ces résultats doivent être interprétés avec prudence, car la performance peut dépendre de plusieurs facteurs externes tels que la zone d'affectation, le portefeuille client ou la nature des produits vendus.

Cette page permet ainsi de répondre aux questions suivantes : quels employés contribuent le plus au chiffre d'affaires ? Comment la performance varie-t-elle selon les profils ? Existe-t-il des écarts significatifs entre les groupes d'employés ? Quels profils nécessitent un accompagnement ou une analyse complémentaire ?

4.6 Synthèse des apports des tableaux de bord

Les tableaux de bord Power BI développés dans ce projet permettent de couvrir plusieurs niveaux d'analyse. La page ventes fournit une vision globale de la performance commerciale. La page produits permet d'étudier la contribution du catalogue. La page clients apporte une lecture orientée comportement et fidélisation. La page employés permet de suivre la contribution individuelle et collective des vendeurs. Enfin, la page panier ajoute une dimension data mining en révélant les associations entre produits.

L'ensemble de ces pages transforme l'entrepôt de données en un véritable outil d'aide à la décision. Les visualisations ne se limitent pas à présenter les données ; elles permettent d'identifier des tendances, de comparer les performances, de détecter des opportunités commerciales et de soutenir des décisions opérationnelles.

Ainsi, Power BI constitue la couche finale du projet décisionnel. Il rend les données accessibles, interactives et exploitables par les utilisateurs métiers.

Chapitre 5

Data Mining : Analyse du panier

5.1 Introduction

Dans le cadre de ce projet décisionnel, une étape de *data mining* a été intégrée afin de dépasser la simple visualisation descriptive des indicateurs de vente. L'objectif est d'extraire des connaissances à partir des transactions clients et d'identifier des relations significatives entre les produits achetés ensemble.

La méthode retenue est l'analyse du panier, également appelée *Market Basket Analysis*. Cette technique permet de détecter les associations fréquentes entre les produits au sein des transactions. Elle est largement utilisée dans les systèmes décisionnels commerciaux pour comprendre les comportements d'achat, proposer des recommandations de produits complémentaires et soutenir les actions marketing.

Dans ce projet, l'analyse du panier a été réalisée à partir des données transactionnelles disponibles dans l'entrepôt PostgreSQL, puis exploitée dans Power BI à travers une page dédiée du tableau de bord.

5.2 Objectif de l'analyse

L'objectif principal de l'analyse du panier est de répondre à la question suivante :

Quels produits sont fréquemment achetés ensemble dans une même transaction ?

Cette analyse permet d'identifier des combinaisons de produits présentant un intérêt commercial. Lorsqu'une association forte est détectée entre deux produits, elle peut être utilisée pour recommander un produit complémentaire, créer une offre groupée ou améliorer l'organisation des produits.

Les résultats de cette analyse peuvent être exploités pour :

- recommander des produits complémentaires aux clients ;
- créer des promotions ou des offres groupées ;
- améliorer l'organisation des produits dans les rayons ;

- cibler les campagnes marketing ;
- augmenter le panier moyen et la valeur des transactions.

Apport du data mining

L'analyse du panier transforme les données transactionnelles en règles d'association exploitables. Elle permet donc de passer d'une analyse descriptive des ventes à une analyse plus avancée du comportement d'achat.

5.3 Données utilisées

L'analyse repose sur une table transactionnelle appelée `DF_Basket`. Cette table représente les produits achetés dans chaque panier. Chaque ligne correspond à un produit appartenant à une transaction donnée.

La structure utilisée pour cette analyse contient principalement :

- `id_transaction` : l'identifiant unique de la transaction ;
- `productname` : le nom du produit acheté.

Ainsi, lorsqu'une transaction contient plusieurs produits, ces produits apparaissent sur plusieurs lignes avec le même identifiant de transaction. Cette organisation permet de comparer les produits entre eux et d'identifier les paires qui apparaissent fréquemment dans les mêmes paniers.

id_transaction	productname
1	whole milk
1	eggs
1	bread
2	whole milk
2	butter
3	coffee
3	sugar

TABLE 5.1 – Exemple simplifié de structure transactionnelle utilisée pour l'analyse du panier

5.4 Principe méthodologique

La méthodologie adoptée consiste à générer les différentes paires possibles de produits, puis à mesurer la force de l'association entre chaque paire. Afin d'éviter les

répétitions, chaque couple de produits est conservé une seule fois.

Par exemple, l'association *bread - butter* est considérée comme équivalente à *butter - bread*. Une seule combinaison est donc retenue dans la table d'analyse.

La table finale d'analyse contient les informations suivantes :

- le premier produit de la paire ;
- le deuxième produit de la paire ;
- une colonne d'affichage sous la forme *Produit 1 - Produit 2* ;
- le support de l'association ;
- la confiance dans les deux directions ;
- le lift de l'association.

Cette structure permet ensuite de construire les visualisations dans Power BI et d'identifier les associations les plus pertinentes d'un point de vue commercial.

5.5 Métriques d'association

Trois métriques principales ont été utilisées pour évaluer la qualité des associations : le support, la confiance et le lift.

5.5.1 Support

Le support mesure la fréquence d'apparition d'une paire de produits dans l'ensemble des transactions.

$$Support(X, Y) = \frac{Nombre\ de\ transactions\ contenant\ X\ et\ Y}{Nombre\ total\ de\ transactions}$$

Un support élevé signifie que les deux produits apparaissent fréquemment ensemble dans les paniers. Cette métrique permet donc de distinguer les associations courantes des associations rares.

Cependant, le support ne suffit pas à lui seul pour juger la qualité d'une association. Une paire peut avoir un support élevé simplement parce que les deux produits sont très populaires séparément, sans qu'il existe nécessairement une relation forte entre eux.

5.5.2 Confiance

La confiance mesure la probabilité d'acheter un produit sachant qu'un autre produit est déjà présent dans le panier.

$$\text{Confidence}(X \rightarrow Y) = \frac{\text{Support}(X, Y)}{\text{Support}(X)}$$

Par exemple, une confiance de 30% pour la règle X vers Y signifie que 30% des transactions contenant le produit X contiennent également le produit Y .

Dans ce projet, la confiance est calculée dans les deux directions :

- Confiance $P1$: probabilité d'acheter le produit 2 sachant que le produit 1 est acheté;
- Confiance $P2$: probabilité d'acheter le produit 1 sachant que le produit 2 est acheté.

Cette distinction est importante, car l'association entre deux produits n'a pas toujours la même signification dans les deux sens. Un produit très fréquent peut être souvent associé à un autre, mais l'inverse peut être moins vrai.

5.5.3 Lift

Le lift mesure la force réelle de l'association entre deux produits en la comparant à une situation d'indépendance.

$$\text{Lift}(X, Y) = \frac{\text{Support}(X, Y)}{\text{Support}(X) \times \text{Support}(Y)}$$

Le lift est un indicateur essentiel pour déterminer si deux produits sont réellement associés. Une valeur supérieure à 1 signifie que les deux produits sont achetés ensemble plus souvent que ce que l'on obtiendrait par hasard.

Valeur du lift	Interprétation
Inférieur à 1	Association négative : les produits sont moins souvent achetés ensemble que prévu.
Égal à 1	Absence d'association particulière : les produits sont statistiquement indépendants.
Entre 1 et 1.5	Association faible, à interpréter avec prudence.
Entre 1.5 et 2	Association intéressante pour une recommandation croisée.
Supérieur à 2	Association forte, pouvant justifier une offre groupée ou une action marketing ciblée.

TABLE 5.2 – Interprétation de la métrique Lift

Dans cette analyse, les associations ayant un lift supérieur ou égal à 1.5 sont considérées comme commercialement pertinentes.

5.6 Intégration dans Power BI

L'analyse du panier a été intégrée dans Power BI à travers une page spécifique du tableau de bord. Cette page permet de visualiser les associations entre les produits et de comparer leurs métriques.

Les principaux éléments affichés sont :

- le nombre total de produits analysés ;
- le nombre total de transactions ;
- un nuage de points représentant les associations selon le support et le lift ;
- un tableau détaillé contenant les valeurs de support, confiance et lift pour chaque paire de produits.

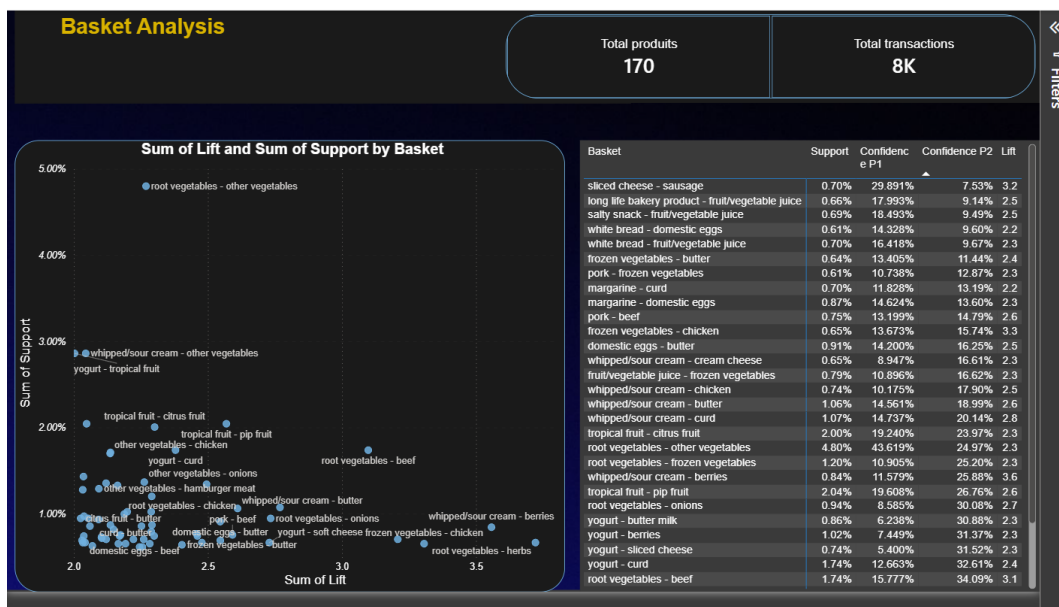


FIGURE 5.1 – Tableau de bord Power BI dédié à l'analyse du panier

La figure 5.1 présente la page Power BI consacrée à l'analyse du panier. Elle affiche notamment un total de 170 produits analysés et environ 8 000 transactions. Le nuage de points permet de comparer les associations de produits selon deux dimensions : le support et le lift. Chaque point représente une paire de produits. Les associations situées vers le haut du graphique présentent un support plus élevé, tandis que celles situées vers la droite présentent un lift plus important.

Le tableau détaillé complète cette visualisation en affichant, pour chaque association, les valeurs de support, de confiance dans les deux directions et de lift. Cette représentation facilite l'identification des associations les plus intéressantes pour la

recommandation croisée, les offres groupées ou l'optimisation du placement des produits.

5.7 Interprétation des résultats

Les résultats obtenus montrent que certaines associations de produits ressortent de manière significative. Certaines paires présentent un support élevé, ce qui signifie qu'elles apparaissent fréquemment dans les transactions. D'autres présentent un lift élevé, indiquant une relation plus forte que le hasard.

Parmi les associations observées dans le tableau de bord, on retrouve par exemple :

- *root vegetables - other vegetables* ;
- *tropical fruit - citrus fruit* ;
- *whipped/sour cream - berries* ;
- *yogurt - curd* ;
- *frozen vegetables - chicken* ;
- *sliced cheese - sausage*.

L'association *root vegetables - other vegetables* présente un support particulièrement élevé, ce qui montre qu'elle apparaît fréquemment dans les paniers. Cette association peut s'expliquer par la complémentarité naturelle entre différentes catégories de légumes.

D'autres associations, comme *whipped/sour cream - berries* ou *sliced cheese - sausage*, présentent un lift élevé. Cela signifie que ces produits sont achetés ensemble plus souvent que prévu dans une situation indépendante. Ces associations sont donc intéressantes pour des recommandations commerciales ciblées.

L'analyse montre également qu'il ne faut pas interpréter une seule métrique de manière isolée. Une association avec un support élevé est fréquente, mais pas toujours spécifique. À l'inverse, une association avec un lift élevé peut être très pertinente, même si elle concerne un volume de transactions plus faible. La sélection des meilleures règles d'association doit donc tenir compte simultanément du support, de la confiance et du lift.

5.8 Exploitation commerciale des résultats

Les résultats de l'analyse du panier peuvent être transformés en actions commerciales concrètes.

Premièrement, les associations fortes peuvent être utilisées pour recommander des produits complémentaires. Lorsqu'un client achète un produit, le système peut proposer un autre produit fréquemment acheté avec celui-ci.

Deuxièmement, l'entreprise peut créer des offres groupées. Les produits présentant un lift élevé peuvent être regroupés dans des promotions afin d'encourager leur achat simultané.

Troisièmement, les résultats peuvent aider à optimiser l'organisation des rayons. Les produits souvent achetés ensemble peuvent être placés à proximité afin de faciliter l'achat et d'améliorer l'expérience client.

Enfin, cette analyse peut soutenir les campagnes marketing ciblées. Les recommandations peuvent être basées sur les comportements réellement observés dans les transactions, ce qui rend les actions commerciales plus pertinentes.

5.9 Limites de l'analyse

Malgré son intérêt, l'analyse du panier présente certaines limites.

Tout d'abord, elle met en évidence des associations statistiques, mais elle ne prouve pas une relation de causalité. Deux produits peuvent être achetés ensemble sans que l'achat de l'un provoque directement l'achat de l'autre.

Ensuite, les résultats dépendent fortement de la qualité des données. Des erreurs dans les transactions, des produits mal nommés ou des données incomplètes peuvent influencer les associations obtenues.

Enfin, certaines associations peuvent être influencées par la saisonnalité, les promotions ou les habitudes locales. Il est donc recommandé de compléter cette analyse par des filtres temporels, géographiques ou par catégorie de produits afin d'obtenir une interprétation plus fine.

5.10 Conclusion

L'analyse du panier constitue une extension importante du système décisionnel réalisé dans ce projet. Elle permet d'enrichir les tableaux de bord Power BI avec une dimension analytique avancée, orientée vers la découverte de comportements d'achat.

Grâce aux métriques de support, confidence et lift, il devient possible d'identifier les produits qui sont fréquemment achetés ensemble et d'évaluer la force de leurs associations. Les résultats obtenus peuvent ensuite être exploités pour la recommandation de produits, la création d'offres groupées, l'optimisation des rayons et l'amélioration des stratégies marketing.

Cette partie montre ainsi comment un entrepôt de données peut servir non seulement à suivre les performances commerciales, mais aussi à produire des connaissances utiles pour la prise de décision.

Chapitre 6

Machine Learning : Prédiction du chiffre d'affaires

6.1 Introduction

Au-delà de l'analyse descriptive réalisée à travers les tableaux de bord Power BI, ce projet intègre une composante de Machine Learning visant à anticiper l'évolution future du chiffre d'affaires. La prédiction des ventes constitue un enjeu stratégique pour les entreprises, car elle permet d'améliorer la planification des ressources, d'optimiser la gestion des stocks et d'orienter les décisions commerciales.

Dans le secteur de la distribution alimentaire, les ventes évoluent généralement selon des tendances et des phénomènes saisonniers. L'identification de ces comportements temporels permet de construire des modèles capables d'estimer les revenus futurs avec un niveau de précision satisfaisant.

L'objectif de cette partie est donc de comparer plusieurs approches de prédiction afin d'identifier le modèle le plus performant pour estimer le chiffre d'affaires futur à partir des données historiques disponibles.

6.2 Construction de la série temporelle

La première étape consiste à transformer les données transactionnelles en série temporelle exploitable par les algorithmes de prédiction.

Les ventes individuelles enregistrées dans la table `fact_sales` sont agrégées selon une fréquence mensuelle. Pour chaque mois, le chiffre d'affaires total est calculé à partir de la somme des montants de vente enregistrés.

Cette agrégation permet d'obtenir une série temporelle de la forme :

Mois	Chiffre d'affaires
Janvier 2021	152 300
Février 2021	147 850
Mars 2021	163 420

TABLE 6.1 – Exemple simplifié de série temporelle mensuelle

Cette représentation permet d'observer directement l'évolution du chiffre d'affaires dans le temps et de mettre en évidence les éventuelles tendances ou variations saisonnières.

6.3 Préparation des données

La qualité des prévisions dépend fortement de la préparation des données. Plusieurs transformations ont donc été réalisées afin d'enrichir la série temporelle et de fournir davantage d'information aux modèles.

6.3.1 Traitement des valeurs aberrantes

Certaines périodes peuvent présenter des comportements atypiques liés à des événements exceptionnels : promotions importantes, ruptures de stock, erreurs de saisie ou événements externes.

Une analyse exploratoire a permis d'identifier ces observations particulières afin de limiter leur impact sur l'apprentissage des modèles.

6.3.2 Création des variables de retard

Les variables de retard (*lag features*) permettent aux modèles d'utiliser les valeurs passées pour prédire les valeurs futures.

Par exemple :

- `Lag_1` : chiffre d'affaires du mois précédent ;
- `Lag_2` : chiffre d'affaires deux mois auparavant ;
- `Lag_3` : chiffre d'affaires trois mois auparavant ;
- `Lag_12` : chiffre d'affaires du même mois l'année précédente.

Ces variables sont particulièrement utiles pour les algorithmes de Machine Learning comme XGBoost ou Random Forest qui ne prennent pas naturellement en compte la dimension temporelle.

6.3.3 Création des moyennes mobiles

Afin de capturer les tendances générales de la série, plusieurs moyennes mobiles ont été calculées :

- moyenne mobile sur 3 mois;
- moyenne mobile sur 6 mois;
- moyenne mobile sur 12 mois.

Ces indicateurs permettent de lisser les fluctuations de court terme et de mieux représenter la dynamique globale des ventes.

6.3.4 Variables calendaires

Des variables temporelles complémentaires ont également été ajoutées :

- mois;
- trimestre;
- année;
- indicateurs saisonniers.

Ces variables permettent aux modèles de détecter des comportements récurrents liés au calendrier.

6.3.5 Séparation entraînement-test

Afin d’évaluer les performances de manière réaliste, la série temporelle a été divisée en deux parties :

- un ensemble d’entraînement utilisé pour apprendre les modèles;
- un ensemble de test conservé pour évaluer leur capacité de généralisation.

Contrairement aux problèmes classiques de classification, l’ordre chronologique est strictement respecté afin d’éviter toute fuite d’information (*data leakage*).

6.4 Modèles étudiés

Plusieurs approches ont été comparées afin d’identifier la méthode la plus adaptée au comportement des ventes observées.

6.4.1 Holt-Winters

Le modèle Holt-Winters appartient à la famille des méthodes de lissage exponentiel.

Il est particulièrement adapté aux séries temporelles comportant :

- une tendance ;
- une saisonnalité ;
- des variations relativement régulières.

Le modèle décompose la série en trois composantes :

- niveau ;
- tendance ;
- saisonnalité.

L'avantage principal de Holt-Winters est sa capacité à capturer efficacement les comportements saisonniers tout en conservant une structure relativement simple.

6.4.2 XGBoost

XGBoost (*Extreme Gradient Boosting*) est un algorithme d'ensemble basé sur la construction séquentielle d'arbres de décision.

Il est réputé pour :

- sa capacité à modéliser des relations non linéaires ;
- ses excellentes performances sur de nombreux problèmes de prédiction.

Dans notre projet, XGBoost exploite les variables temporelles construites lors de la phase de préparation.

6.4.3 Random Forest

Random Forest est une méthode d'ensemble reposant sur la combinaison d'un grand nombre d'arbres de décision.

Chaque arbre est entraîné sur un sous-échantillon aléatoire des données, puis les prédictions sont agrégées.

Cette approche réduit généralement le risque de surapprentissage mais peut rencontrer des difficultés pour modéliser certaines dépendances temporelles complexes.

6.4.4 SARIMA

SARIMA (*Seasonal AutoRegressive Integrated Moving Average*) est une extension du modèle ARIMA intégrant explicitement la saisonnalité.

Ce modèle repose sur :

- une composante autorégressive ;
- une composante de différenciation ;
- une composante moyenne mobile ;

— une composante saisonnière.

SARIMA est souvent utilisé comme référence dans les problèmes de prévision temporelle.

6.4.5 Ensemble pondéré

Enfin, un modèle hybride a été construit en combinant plusieurs prédictions individuelles.

Le principe consiste à calculer une moyenne pondérée des prévisions produites par différents modèles afin de bénéficier de leurs complémentarités.

Cette approche permet souvent d’obtenir une meilleure stabilité des résultats.

6.5 Résultats expérimentaux

Les performances obtenues sont résumées dans le tableau suivant.

Rang	Modèle	MAPE	R ²
1	Holt-Winters	4,92%	0,8678
2	Ensemble pondéré	5,27%	0,8111
3	XGBoost	5,56%	0,8184
4	Random Forest	11,94%	0,2128
5	SARIMA	46,76%	-9,2000

TABLE 6.2 – Comparaison des performances des modèles

6.6 Analyse des résultats

Les résultats montrent clairement la supériorité du modèle Holt-Winters sur ce jeu de données.

Avec un MAPE de seulement 4,92%, le modèle produit des prévisions très proches des valeurs réellement observées. Son coefficient de détermination de 0,8678 indique qu’il explique une grande partie de la variabilité du chiffre d’affaires.

Cette performance suggère que la série étudiée présente une structure temporelle relativement régulière, dominée par une tendance et une saisonnalité que Holt-Winters parvient à capturer efficacement.

XGBoost obtient également des résultats satisfaisants avec un MAPE de 5,56%. Cette performance confirme que les variables temporelles créées lors de la préparation

apportent une information pertinente au modèle.

L'ensemble pondéré améliore légèrement la stabilité des prédictions mais ne parvient pas à dépasser Holt-Winters.

Random Forest présente des performances plus modestes, ce qui peut s'expliquer par une difficulté à reproduire précisément les mécanismes saisonniers observés dans la série.

Enfin, SARIMA affiche des résultats très faibles. Son coefficient R^2 négatif indique que ses prévisions sont moins performantes qu'une simple approximation basée sur la moyenne historique.

Résultat principal

Le modèle Holt-Winters obtient les meilleures performances avec un MAPE de 4,92% et un coefficient R^2 de 0,8678. Ces résultats montrent qu'il constitue la solution la plus adaptée pour prévoir le chiffre d'affaires dans le contexte étudié.
--

6.7 Conclusion

Cette phase de Machine Learning a permis de comparer plusieurs approches de prévision appliquées au chiffre d'affaires de l'entreprise.

Les résultats montrent que les méthodes spécialisées dans les séries temporelles, et plus particulièrement Holt-Winters, sont les plus adaptées aux caractéristiques du dataset étudié. Grâce à un faible niveau d'erreur et à une bonne capacité de généralisation, ce modèle a été retenu comme solution de référence pour la prévision des ventes futures.

Cette composante prédictive complète l'architecture décisionnelle du projet en ajoutant une dimension prospective aux analyses descriptives réalisées dans Power BI. Elle permet ainsi de passer d'une logique de compréhension du passé à une logique d'anticipation et d'aide à la décision.

Chapitre 7

Discussion et limites

7.1 Analyse critique du projet

La réalisation de ce projet a permis de mettre en œuvre l'ensemble des composantes d'une chaîne décisionnelle moderne, depuis la préparation des données jusqu'à la restitution des résultats sous forme de tableaux de bord et de modèles prédictifs. Au-delà des résultats obtenus, il est important d'évaluer de manière critique les choix techniques réalisés, les bénéfices apportés par la solution ainsi que les limites rencontrées au cours du développement.

Cette phase de discussion permet de prendre du recul sur l'ensemble de l'architecture mise en place et d'identifier les pistes d'amélioration susceptibles d'accroître la robustesse, la maintenabilité et la valeur analytique du système.

7.2 Forces du projet

Le projet présente plusieurs points forts qui contribuent à sa cohérence et à sa valeur décisionnelle.

7.2.1 Une chaîne décisionnelle complète

L'un des principaux apports du projet réside dans sa couverture complète du cycle de vie des données. Contrairement à de nombreux projets limités à la visualisation ou à la modélisation prédictive, cette réalisation intègre l'ensemble des étapes nécessaires à la construction d'une solution analytique opérationnelle.

La démarche mise en œuvre comprend :

- la collecte et la préparation des données avec Python ;
- la conception d'un fichier analytique dénormalisé ;
- la mise en place d'un pipeline ETL avec Apache Hop ;
- la création d'un entrepôt de données PostgreSQL ;

- la modélisation décisionnelle sous forme de schéma en étoile ;
- la réalisation de tableaux de bord Power BI ;
- l'intégration d'algorithmes de Data Mining ;
- l'implémentation de modèles de Machine Learning pour la prévision.

Cette approche permet de reproduire les différentes couches d'une architecture BI réellement utilisée dans les organisations.

7.2.2 Une modélisation adaptée à l'analyse décisionnelle

Le choix du schéma en étoile constitue un autre point fort du projet. Cette modélisation est largement utilisée dans les systèmes décisionnels en raison de sa simplicité et de ses performances.

La séparation entre la table de faits et les dimensions permet :

- une meilleure lisibilité des données ;
- des requêtes analytiques plus performantes ;
- une intégration simplifiée dans Power BI ;
- une meilleure compréhension par les utilisateurs métiers.

Cette structure facilite également l'ajout futur de nouvelles dimensions ou de nouveaux indicateurs.

7.2.3 Des tableaux de bord orientés métier

Les tableaux de bord développés dans Power BI ne se limitent pas à présenter des graphiques descriptifs. Ils ont été organisés selon les principaux axes de décision de l'entreprise :

- performance commerciale ;
- analyse produit ;
- comportement client ;
- performance des employés ;
- analyse du panier d'achat.

Cette organisation permet aux décideurs d'accéder rapidement aux informations pertinentes et de naviguer efficacement entre différents niveaux d'analyse.

L'utilisation de filtres interactifs et de visualisations dynamiques améliore également l'exploration des données et facilite l'identification des tendances importantes.

7.2.4 Une dimension Data Mining à forte valeur ajoutée

L'intégration de l'analyse du panier apporte une dimension supplémentaire au projet.

Alors que les tableaux de bord répondent principalement à des questions descriptives telles que :

« Que s'est-il passé ? »

l'analyse du panier permet de répondre à une problématique plus avancée :

« Quels comportements d'achat peut-on découvrir dans les données ? »

Les règles d'association obtenues peuvent être directement exploitées pour :

- recommander des produits ;
- créer des offres promotionnelles ;
- améliorer l'organisation des rayons ;
- augmenter le panier moyen.

Cette composante démontre l'intérêt d'intégrer des techniques de Data Mining dans une plateforme décisionnelle.

7.2.5 Une approche comparative en Machine Learning

Plutôt que de se limiter à un seul algorithme de prévision, plusieurs modèles ont été évalués et comparés.

Cette démarche présente plusieurs avantages :

- validation objective des performances ;
- comparaison de différentes familles d'algorithmes ;
- justification du choix du modèle final ;
- meilleure compréhension du comportement de la série temporelle.

Les métriques utilisées permettent d'obtenir une évaluation rigoureuse de la qualité des prévisions et renforcent la crédibilité des résultats obtenus.

7.3 Limites identifiées

Malgré les résultats obtenus, plusieurs limites ont été identifiées au cours du projet.

7.3.1 Gestion des relances du pipeline ETL

La première limite concerne l'idempotence du pipeline ETL.

Dans sa version actuelle, une exécution répétée du processus peut entraîner la duplication des données si les tables ne sont pas préalablement vidées.

Bien qu'une stratégie de type `TRUNCATE + LOAD` ait été mise en place, une solution plus robuste reposerait sur des mécanismes de chargement incrémental ou d'*upsert* permettant :

- la mise à jour automatique des enregistrements existants ;
- l'insertion des nouvelles données uniquement ;
- la réduction des temps de chargement.

7.3.2 Automatisation limitée des contrôles qualité

Les vérifications de qualité des données sont actuellement réalisées principalement lors des phases de préparation et de validation.

Cependant, ces contrôles pourraient être davantage automatisés afin de détecter systématiquement :

- les valeurs manquantes ;
- les incohérences métier ;
- les anomalies statistiques ;
- les violations de contraintes référentielles.

Une automatisation complète permettrait d'améliorer la fiabilité globale du système.

7.3.3 Absence d'orchestration centralisée

Les différentes composantes du projet fonctionnent correctement mais restent relativement indépendantes.

L'exécution complète nécessite encore plusieurs interventions manuelles :

- préparation des données ;
- exécution du pipeline Apache Hop ;
- actualisation de Power BI ;
- exécution des notebooks d'analyse.

Une solution d'orchestration permettrait d'automatiser l'ensemble du processus et de faciliter la maintenance.

7.3.4 Industrialisation limitée des modèles prédictifs

Les modèles de Machine Learning ont été développés dans un objectif analytique et pédagogique.

Cependant, dans une perspective de mise en production, plusieurs éléments supplémentaires seraient nécessaires :

- sauvegarde des modèles entraînés ;

- versionnement des modèles ;
- automatisation du réentraînement ;
- suivi des performances dans le temps ;
- déploiement sous forme de service de prédiction.

L'absence de ces mécanismes limite actuellement l'exploitation opérationnelle des prévisions.

7.3.5 Limites liées aux données

Les performances obtenues dépendent fortement de la qualité et de la richesse du jeu de données utilisé.

Certaines informations potentiellement utiles ne sont pas disponibles :

- campagnes promotionnelles ;
- événements saisonniers particuliers ;
- niveau des stocks ;
- données concurrentielles ;
- informations économiques externes.

L'intégration de ces variables pourrait améliorer la précision des analyses et des prévisions.

7.4 Perspectives et améliorations futures

Plusieurs pistes d'évolution peuvent être envisagées afin d'enrichir et de professionnaliser davantage la solution développée.

7.4.1 Renforcement de la qualité des données

Une première amélioration consisterait à intégrer un véritable framework de contrôle qualité permettant :

- la validation automatique des données ;
- la détection des anomalies ;
- la génération de rapports qualité ;
- le suivi de la qualité dans le temps.

7.4.2 Automatisation complète de la chaîne décisionnelle

La mise en place d'un orchestrateur tel qu'Apache Airflow permettrait d'automatiser :

- les traitements Python;
- les chargements ETL;
- les mises à jour PostgreSQL;
- les rafraîchissements Power BI;
- les processus de Machine Learning.

Cette automatisation améliorerait la reproductibilité et réduirait les interventions manuelles.

7.4.3 Évolution du Data Mining

L'analyse du panier pourrait être enrichie par :

- l'utilisation de l'algorithme Apriori;
- l'utilisation de FP-Growth;
- l'analyse des séquences d'achat;
- des recommandations personnalisées par client.

Ces extensions permettraient d'obtenir des connaissances plus fines sur le comportement des consommateurs.

7.4.4 Amélioration des modèles de prévision

De nouveaux modèles pourraient être évalués :

- Prophet;
- LightGBM;
- CatBoost;
- LSTM;
- Temporal Fusion Transformer.

L'ajout de variables exogènes pourrait également améliorer la qualité des prévisions.

7.4.5 Déploiement en environnement réel

Une dernière perspective consiste à transformer cette solution académique en plateforme décisionnelle opérationnelle.

Cela impliquerait notamment :

- l'hébergement de la base de données;
- l'automatisation des flux;
- la publication des tableaux de bord;
- la sécurisation des accès;
- la supervision des traitements.

Conclusion

Ce projet a permis de concevoir et de mettre en œuvre une solution décisionnelle complète dédiée à l'analyse des ventes d'une enseigne de distribution alimentaire.

À partir de données transactionnelles brutes, une architecture analytique intégrée a été construite. Les données ont été préparées et transformées à l'aide de Python, puis chargées dans un entrepôt PostgreSQL au travers d'un pipeline ETL développé avec Apache Hop. Une modélisation en étoile a ensuite été mise en place afin de faciliter les analyses multidimensionnelles et l'exploitation des données dans Power BI.

Les tableaux de bord réalisés permettent de suivre efficacement les principaux indicateurs de performance liés aux ventes, aux produits, aux clients et aux employés. Ils offrent une vision synthétique et interactive de l'activité commerciale tout en facilitant l'identification des tendances et des opportunités d'amélioration.

Le projet ne se limite toutefois pas à une approche descriptive. L'intégration d'une analyse du panier a permis de découvrir des associations significatives entre les produits et d'extraire des connaissances directement exploitables dans un contexte commercial. Par ailleurs, la mise en œuvre de plusieurs modèles de prévision a permis d'ajouter une dimension prédictive à la plateforme décisionnelle et de démontrer la capacité des techniques de Machine Learning à anticiper l'évolution future du chiffre d'affaires.

Les résultats obtenus montrent qu'une approche intégrant Business Intelligence, Data Mining et Machine Learning permet non seulement de comprendre les performances passées, mais également de soutenir la prise de décision future. Cette complémentarité entre analyse descriptive, découverte de connaissances et prévision constitue l'un des principaux apports du projet.

Enfin, cette réalisation fournit une base solide pour des développements futurs orientés vers l'automatisation complète des traitements, l'amélioration des modèles prédictifs et l'industrialisation de l'ensemble de la chaîne décisionnelle. Elle illustre concrètement la manière dont les technologies modernes de gestion et d'analyse des données peuvent être combinées pour créer un système d'aide à la décision performant et évolutif.

Annexe A

Annexes

A.1 Organisation du projet

Listing A.1 – Structure synthétique du répertoire projet

```
PowerBi_mining_ML/  
  Data_Preprocessing/  
  Apache HOP/  
  Power bi/  
  AI/  
  Images/  
  README.md
```

A.2 Technologies utilisées

Domaine	Technologies
Préparation des données	Python, pandas, Jupyter Notebook
ETL	Apache Hop
Base de données	PostgreSQL
Visualisation	Power BI, DAX
Data mining	Market Basket Analysis, support, confiance, lift
Machine Learning	Holt-Winters, XGBoost, Random Forest, ensemble pondéré
Évaluation	MAE, RMSE, MAPE, sMAPE, R^2 , MASE

TABLE A.1 – Synthèse des technologies utilisées